

Guía Tema 4: Muestreo y distribución de muestreo

Profesor: Álvaro Vidal Cruz
Estadísticas y Data Science (EST108)
Universidad Adolfo Ibáñez

Ejercicio 1

Identifique la población en estudio de los siguientes casos prácticos. Luego, identifique y justifique si las cantidades indicadas corresponden a un parámetro o a una estimación. Por último, para cada cantidad determine cual es el parámetro o el parámetro que se está estimando.

- a. Según una encuesta que fue aplicada a 860 personas que residen en una determinada comuna del país, se determinó que **1 de cada 6 residentes** están satisfechos con los servicios de transporte público.
- b. En un estudio sobre el nivel de contaminación ambiental en una región, se determinó que la concentración media de partículas PM2.5 en toda el área de estudio es de **15 microgramos por metro cúbico**, lo cual posteriormente fue corroborado por diferentes estimaciones de estudios posteriores.
- c. Según un estudio realizado en una universidad, tomando una muestra de estudiantes de la generación del año anterior, el **82 %** de los estudiantes de segundo año aprueba el examen de estadísticas.
- d. En una empresa se estudia la distribución y la variabilidad de los sueldos de sus empleados, en donde se detectó que la desviación estándar de todos sus trabajadores es de **\$254 mil pesos chilenos**.
- e. Un banco está interesado en conocer el nivel de satisfacción de sus clientes con respecto a los servicios relacionados a préstamo de dinero en sus diferentes sucursales. Se tomó una muestra de 500 clientes y se les aplicó una encuesta para evaluar su satisfacción y recopilar sugerencias de mejora, obteniendo entre uno de sus tantos resultados que el **64 %** de los clientes declara que "Me siento satisfecho con el servicio", siendo el complemento los que opinan "Me siento insatisfecho con el servicio".
- f. Una empresa de alimentación desea evaluar la aceptación de un nuevo producto alimenticio en el mercado dentro de los clientes que consumen sus productos. Se seleccionaron al azar una muestra de 2000 consumidores de diferentes edades y ubicaciones geográficas, y se les pidió que probaran el producto y brindaran su opinión sobre su sabor, calidad y precio. Se obtuvo como resultados que la edad media de los consumidores que declaran que comprarían el producto es de **25 años** y que el **80 %** de los habitantes de zonas rurales declararon que el precio es elevado.

- g. El departamento del tránsito de la municipalidad de una pequeña comuna estudia los pagos por concepto de patentes que les entregan todos sus habitantes durante la última década, en donde se sabe que la varianza del número de pagos que llegan por temas de patentes de todos sus habitantes es de **6 patentes²** y que se reciben en promedio **80 solicitudes** de pagos por concepto de patentes por cada año entre sus habitantes.
- h. Se lleva a cabo una encuesta en una universidad para determinar el promedio de horas de estudio de los estudiantes, tomando una muestra aleatoria de 300 estudiantes de diferentes carreras de la institución. Los resultados revelan que el promedio es de **5 horas** de estudio por semana, con una desviación estándar de **1,5 horas**.

Ejercicio 2

Muchos medicamentos empleados en la cura del cáncer son costosos. Business Week dio a conocer los costos de los tratamientos con Herceptin, un medicamento suministrado para el cáncer de mama (*Business Week*, 30 de enero de 2006). Los siguientes son los costos (en dólares) de tratamientos comunes con Herceptin en una muestra aleatoria de simple de 10 pacientes: 4.376, 5.578, 2.217, 4.920, 4.495, 4.798, 6.446, 4.119, 4.237 y 3.814

- a. Calcule una estimación del costo medio de un tratamiento con Herceptin.
- b. Calcule una estimación del costo mediano de un tratamiento con Herceptin.
- c. Estime la varianza para los costos de los tratamientos con Herceptin
- d. Estime la desviación estándar para los costos de los tratamientos con Herceptin


Ejercicio 3

En una muestra de 50 empresas de la lista Fortune 500 (*Fortune*, 14 de abril de 2003), la cual contempla un listado total de 500 empresas del mundo; cinco se encontraban en Nueva York, seis en California, dos en Minnesota y una en Wisconsin.

- a. Calcule una estimación de la proporción de empresas de Fortune 500 con sede en Nueva York.
- b. Calcule una estimación del número de empresas de Fortune 500 ubicadas en Minnesota.
- c. Calcule una estimación de la proporción de empresas de Fortune 500 que no se encuentran ubicadas en ninguno de los estados mencionados.

Ejercicio 4

En la siguiente figura se muestran histogramas, generados con muestras de tamaño 1000, de la distribución de muestreo de tres estimadores para la media de la variable aleatoria X proveniente desde una población que posee distribución Normal de media poblacional igual a 5.




Responda las siguientes preguntas planteadas:

- ¿Cuáles estimadores se podrían pensar que son insesgados? Justifique.
- ¿Qué estimador parece tener el sesgo más grande? Justifique.
- ¿Qué estimador parece ser el más eficiente? Justifique.

Ejercicio 5

En la siguiente figura se muestran tres diagramas de caja: para las medias, medias truncadas (eliminando el 10 % inferior y 10 % superior de los datos) y medianas para muestras de tamaño 10 de una cierta población con presencia de algunos datos atípicos.



Suponiendo que la media poblacional es igual a cero, responda las siguientes preguntas planteadas:

- ¿Parecen insesgados estos estimadores? Justifique.
- ¿Qué estimador parece ser más eficiente? Justifique.

Ejercicio 6

Se consideran los siguientes estimadores para estimar la varianza poblacional:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \quad s_n^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

En donde se sabe que $\mathbb{E}(s^2) = \sigma^2$ y que $\mathbb{E}(s_n^2) = \frac{\sigma^2(n-1)}{n}$.

- ¿Cuál estimador es insesgado? Justifique.
- Encuentre el sesgo asociado a ambos estimadores.

Ejercicio 7

La lectura de un voltímetro conectado a un circuito de prueba tiene una distribución uniforme en el intervalo $(\theta, \theta + 1)$, en donde θ es el verdadero, pero desconocido, voltaje del circuito. Suponga que $Y_1, Y_2, \dots, Y_n$ es una muestra aleatoria de tales lecturas, las cuales son independientes e idénticamente distribuidas con $\mathbb{E}(Y) = \frac{a+b}{2}$ y $\mathbb{V}(Y) = \frac{(b-a)^2}{12}$. Estudie las propiedades de los siguientes estimadores y responda las preguntas planteadas:

$$\hat{\theta}_1 = \bar{y} - \frac{1}{2} \quad \text{y} \quad \hat{\theta}_2 = \frac{nY_1 - Y_3 + Y_5}{n} - \frac{1}{2}$$

En donde se sabe que $\mathbb{E}(\hat{\theta}_1) = \mathbb{E}(\hat{\theta}_2) = \theta$. Además, se conoce que $\mathbb{V}(\hat{\theta}_1) = \frac{1}{12n}$ y que $\mathbb{V}(\hat{\theta}_2) = \frac{1}{12}$

- Determinar si los estimadores propuestos son insesgados. Luego, determine el sesgo respectivo para ellos.
- Evalúe la eficiencia entre ambos estimadores. ¿Cuál de los 2 estimadores propuestos es más eficiente?
- ¿Qué estimador le propondría usted al fabricante? Justifique.

Ejercicio 8

Un emprendedor requiere estimar la venta media de su producto en cierto periodo (en miles de pesos), por lo que le consulta a un asesor una propuesta de dos estimadores en base a una muestra aleatoria de ventas de su producto de tamaño n y de la forma $X_1, X_2, \dots, X_n$, independientes e idénticamente distribuidas con $\mathbb{E}(X) = \mu$ y $\mathbb{V}(X) = \sigma^2$. Dado esto, considere los siguientes estimadores propuestos por el asesor:

$$\hat{\theta}_1 = \frac{5X_1 + 3X_n}{n} \quad \text{y} \quad \hat{\theta}_2 = \frac{\sum_{i=1}^n X_i}{n+1}$$

En donde se sabe que $\mathbb{E}(\hat{\theta}_1) = \frac{8\mu}{n}$ y que $\mathbb{E}(\hat{\theta}_2) = \frac{n\mu}{n+1}$. Además, se conoce que $\mathbb{V}(\hat{\theta}_1) = \frac{34\sigma^2}{n^2}$ y que $\mathbb{V}(\hat{\theta}_2) = \frac{n\sigma^2}{(n+1)^2}$

El fabricante requiere saber cuál de los estimadores es el mejor para la estimación, por lo que le solicita a usted que evalúe las siguientes características del estimador:

- ¿Cuál es el parámetro en estudio? ¿Y qué representa en el contexto del caso?
- Determine si los estimadores propuestos son insesgados.
- Determine el sesgo asociado a cada estimador.

Ejercicio 9

Suponga que en las jornadas de trabajo de una empresa se deben transportar containers de productos comestibles mediante un elevador de carga. Se sabe que el elevador puede transportar un máximo de 250 libras de peso, ya que de lo contrario necesita ser recalibrado. Además, por antecedentes de la distribuidora de los productos comestibles, se sabe que el peso de todos los containers de este tipo se ajustan a una distribución de probabilidad no determinada con media 230 libras y desviación estándar de 80 libras. Mediante un muestreo aleatorio sistemático, y con la intención de ir conociendo las exigencias a la cual se somete el elevador de carga, se lleva el registro del peso de 60 containers transportados durante las jornadas de trabajo.

- a. Encuentre la probabilidad de que el peso medio de los containers no exceda el máximo permitido por el elevador de carga.

Ejercicio 10

Los tiempos de servicio para los clientes que pasan por la caja en una concurrida tienda -que se caracteriza por atender rápidamente a sus clientes- son variables aleatorias independientes e idénticamente distribuidas con media de 1.5 minutos y varianza de 1.0 minutos². Como hay una sola caja en la tienda, los clientes son atendidos de tal forma que cuando finaliza la atención de un cliente empieza inmediatamente la atención del cliente siguiente.

- a. Calcule la probabilidad de que 100 clientes puedan ser atendidos en menos de 2 horas de tiempo total de servicio. ¿Cree usted que es factible que estos 100 clientes puedan ser atendidos en menos de 2 horas? Interprete.
- b. Con el fin de optimizar el servicio, se solicita un personal auxiliar a la caja si los tiempos de servicio para los clientes son en promedio mayores a 1.7 minutos. Calcule la probabilidad de que llegue un personal auxiliar considerando que pasan 52 clientes por la caja. ¿Qué tan probable es que llegue el personal auxiliar a la caja?

Ejercicio 11

Suponga que la demanda semanal X de sacos de 5 onzas de harina en un Emporio tiene una distribución normal con media de 72 sacos y una desviación estándar de 1,6 sacos. Suponga que se ha tomado una muestra aleatoria de tamaño 15 y responda las siguientes enunciados:

- a. ¿Cuál es la probabilidad que la demanda media semanal de la muestra supere los 73 sacos de harina? Interprete su resultado.
- b. Encuentre un valor de k , tal que $\mathbb{P}(72 - k \leq \bar{X} \leq 72 + k) = 0,95$. Interprete su resultado.

Ejercicio 12

Suponga que la cantidad de producción de trigo durante una temporada en una cierta empresa es una variable aleatoria con distribución no determinada que posee una media de 85 toneladas y una desviación estándar de 20 toneladas. Suponga que se ha tomado una muestra aleatoria de tamaño 55 y responda los siguientes enunciados:

- a. ¿Cuál es la probabilidad que la cantidad media de producción de trigo de la muestra supere las 90 toneladas? Interprete su resultado.
- b. Encuentre un valor de k , tal que $\mathbb{P}(100 - k \leq \bar{x} \leq 100 + k) = 0,9$. Interprete su resultado.

Respuestas

Ejercicio 1:

- a. Población: residentes de la comuna. El 16,6 % (1 de cada 6 residentes) corresponde a una estimación, ya que se calcula a partir de una muestra de residentes de la ciudad que participaron en la encuesta. El parámetro poblacional corresponde al porcentaje o proporción (p) de residentes satisfechos con los servicios de transporte público.
- b. Población: microorganismos en la región bajo estudio. Los 15 microgramos por metro cúbico corresponden al valor de un parámetro poblacional, ya que se calcula considerando toda la región bajo estudio. El parámetro poblacional corresponde a la concentración media (μ) de partículas PM2.5 en la región.
- c. Población: estudiantes de segundo año de la universidad. El 82 % corresponde a una estimación, ya que se calcula a partir de una muestra de estudiantes de la generación del año anterior. El parámetro poblacional corresponde al porcentaje o proporción (p) de estudiantes de segundo año que aprueba el examen de estadísticas.
- d. Población: empleados de una empresa. El \$254 mil pesos chilenos corresponden al valor del parámetro poblacional, ya que se calcula con todos los empleados de la empresa. El parámetro poblacional corresponde a la desviación estándar (σ) del sueldo de los empleados de la empresa.
- e. Población: clientes del banco de las diferentes sucursales. El 64 % ($\hat{p}$) representa una estimación dado que es una cantidad obtenida a través de una muestra de 500 clientes. El parámetro que se está estimando corresponde a la proporción p de los clientes que declaran "Me siento satisfecho con el servicio".
- f. Población: clientes que consumen los productos de la empresa de alimentación. Los 25 años de edad ($\bar{x}$) y el 80 % ($\hat{p}$) corresponden a estimaciones dado que son valores que se obtienen a través de una muestra de 2000 consumidores. Los 25 años están estimando la edad media μ de los clientes que declaran que comprarían el producto. Por su parte, el 80 % está estimando la proporción p de clientes que habitan en zonas rurales que declararon que el precio es elevado.
- g. Población: habitantes de la comuna durante la última década. Las 6 patentes² (σ^2) y las 80 solicitudes (μ) corresponden a parámetros dado que se tratan de valores obtenidos con los datos de toda la población en estudio. Las 6 patentes² es la varianza σ^2 del número de pagos que llegan por temas de patentes y las 80 solicitudes es la media μ del número de solicitudes por conceptos de pago de patentes que se reciben por año.
- h. Población: estudiantes de la universidad. Las 5 horas y 1,5 horas corresponden a estimaciones, ya que se calculan a partir de los resultados de la encuesta realizada en la universidad. El promedio de 5 horas por semana representa una estimación del promedio (μ) de horas de estudio de los estudiantes en la universidad. La desviación estándar de 1,5 horas representa una estimación de la desviación estándar (σ) del tiempo de estudio de los estudiantes en la universidad.

Ejercicio 2:

- a. $\bar{x} = 4.500$
- b. $Me = 4.435,5$
- c. $s^2 = 1.236.290$
- d. $s = 1.111,886$

Ejercicio 3:

- a. $\hat{p} = 0,1$
- b. 20 empresas.
- c. $\hat{p} = 0,72$

Ejercicio 4:

- a. Como las distribuciones muestrales de los estimadores 1 y 3 son aproximadamente simétricas en torno a $\mu = 5$ (es decir, que poseen un valor esperado igual a 5), se puede establecer que dichos estimadores son insesgados.
- b. Dado que el estimador 1 y el estimador 3 son aparentemente insesgados, es posible decir que tienen un sesgo igual a 0. Por otro lado, el estimador 2 es sesgado, lo que implica que su sesgo es mayor que 0. Por lo tanto, el estimador 2 es el que posee el sesgo más grande.
- c. Para evaluar la eficiencia debemos considerar la curva más estrecha entre todas, en donde se puede apreciar la desviación estándar de los estimadores. De este modo, el estimador que posee la desviación estándar más baja es el estimador 1. Por lo tanto, se puede concluir que el estimador 1 es más eficiente.

Ejercicio 5:

- a. Como las distribuciones muestrales de los 3 estimadores son aproximadamente simétricas en torno a $\mu = 0$, se puede establecer que dichos estimadores son insesgados.
- b. Como las distribuciones muestrales de los 3 estimadores son aproximadamente simétricas en torno a $\mu = 0$, al considerar un diagrama de caja y bigotes más estrecha se puede establecer que la desviación estándar de la mediana es menor que la desviación estándar de la media y y media truncada, a pesar de la presencia de algunos datos atípicos. Por lo tanto, se puede concluir que el la mediana es más eficiente.

Ejercicio 6:

- a. Tan sólo s^2 es un estimador insesgado para σ^2 dado que $\mathbb{E}(s^2) = \sigma^2$
- b. $B(s^2) = 0$ y $B(s_n^2) = -\frac{\sigma^2}{n}$

Ejercicio 7:

- a. Ambos estimadores son insesgados dado que $\mathbb{E}(\hat{\theta}_1) = \theta$ y que $\mathbb{E}(\hat{\theta}_2) = \theta$. El sesgo asociado a cada estimador es $B(\hat{\theta}_1) = 0$ y $B(\hat{\theta}_2) = 0$
- b. $eff(\hat{\theta}_1, \hat{\theta}_2) = \frac{V(\hat{\theta}_2)}{V(\hat{\theta}_1)} = \frac{1/12}{1/12n} = n$. Si $n > 1$ (el tamaño de muestra no puede ser 0 ni negativo) $\Rightarrow eff(\hat{\theta}_1, \hat{\theta}_2) > 1$, es decir $\hat{\theta}_1$ es más eficiente. En cambio, si $n = 1$ ambos estimadores serían igual de eficientes.
- c. Dado que ambos estimadores propuestos son insesgados, se propondría el más eficiente. Es decir, el mejor estimador para θ es $\hat{\theta}_1$ si $n > 1$. Por su parte, si $n = 1$ ambos estimadores serían igual de convenientes.

Ejercicio 8:

- a. El parámetro en estudio es la media población μ , la cual representa la venta media de un producto en cierto periodo (en miles de pesos).
- b. Ambos estimadores son sesgados dado que $\mathbb{E}(\hat{\theta}_1) \neq \mu$ y que $\mathbb{E}(\hat{\theta}_2) \neq \mu$.
- c. El sesgo asociado a cada estimador es $B(\hat{\theta}_1) = \frac{8\mu - n\mu}{n}$ y $B(\hat{\theta}_2) = -\frac{\mu}{n+1}$

Ejercicio 9:

- a. $\mathbb{P}(\bar{x} < 250) = 0,9736$

Ejercicio 10:

- a. $\mathbb{P}(T < 120) = \mathbb{P}(\bar{x}_{100} < 1,2) = 0,0013$, considerando $T = \sum_{n=1}^{100} X_i$
- b. $\mathbb{P}(\bar{x}_{52} > 1,7) = 0,0746$

Ejercicio 11:

- a. $\mathbb{P}(\bar{x} > 73) = 0,0078$
- b. $k = 0,8097$

Ejercicio 12:

- a. $\mathbb{P}(\bar{x} > 90) = 0,0318$
- b. $k = 0,2957$